hochschule burgenland
University of Applied Sciences

Arbeitstitel: Einsatz von LLMs beim Programmieren-Lernen

Masterarbeit

zur Erlangung des akademischen Grades

Master of Science in Engineering

Master Program Cloud Computing Engineering
Department Informationstechnologie

Eingereicht von:	Tobias Wilhelm, BEd
Personenkennzeichen:	2410781008
Datum:	21. September 2026
Betreut von:	Dipl.-Ing. Dr.techn. Georg Macher, BSc MBA

Vorwort

Hier ist der Platz für persönliche Worte wie zum Beispiel Dankesworte an Betreuer, Berater, Freunde und Familie.

Vorname Familienname

Eisenstadt, 27. Juli 2024

Inhaltsverzeichnis

Kurzfassung . . . . . **v**

Abstract . . . . . **vii**

1 Einleitung **1**
1.1 Problemstellung 1
1.2 Wissenschaftliche Fragestellung 1
1.3 Methodischer Ansatz 2
1.4 Aufbau der Arbeit 2

2 Stand des Wissens / Stand der Technik **3**
2.1 Herausforderungen beim Programmierenlernen im tertiären Bildungsbereich 3
2.2 Die Verwendung von LLMs in der Programmierausbildung 3
2.3 Generative KI in Prüfungen und Bewertungsszenarien 4
2.4 LLM-unterstütztes Programmierenlernen 4
2.5 User-Experience-Messungen von LLM-Chatbots mittels User Experience Questionnaires (UEQ) 5
2.6 Zusammenfassung 6

3 Forschungsmethodik **7**
3.1 Motivation & Zielsetzung 7
3.2 Studiendesign und Versuchsaufbau 7
3.3 Erläuterung der Erhebungsinstrumente: persönlicher Fragebogen und UEQ 7
3.4 Konzeption der Programmieraufgabe: Das „Garden-Simulator"-Framework 7
3.4.1 Der „Garden-Simulator" 7
3.4.2 Programmstruktur des „Garden-Simulators" 7
3.4.3 Erstellung der Aufgaben nach UMC-Framework 8
3.4.4 Musterlösung der Aufgaben und Programmierkonzepte . . 9
3.4.5 Lokale Tests zur Selbstüberprüfung 10
3.5 Bewertungsraster zur Evaluierung der Programmieraufgabe 10
3.5.1 Ergänzung der Dimension „Funktionalität und Robustheit" 13
3.6 Planung der Pilotstudie 14
3.7 Diskussion 14
3.8 Zusammenfassung 14

4 Evaluierung der Studie **15**
4.1 Pilotphase der Studie 15
4.1.1 Durchführung und Erkenntnisse der Pilotstudie 15
4.1.2 Adaptionen für die Hauptstudie 16
4.2 Hauptstudie 16
4.2.1 Evaluierung 16
4.3 Auswertung Fragebogen 1 und UEQ (Fragebogen 2) 16
4.3.1 Fragebogen 1 - Selbsteinschätzung der ProbandInnen 16
4.3.2 UEQ 16
4.4 Diskussion 16

4.5 Zusammenfassung 16

5 Diskussion & Interpretation 17

6 Conclusio 19

Literaturverzeichnis 21

Abbildungsverzeichnis 25

Tabellenverzeichnis 27

Formelverzeichnis 28

Abkürzungen 30

Anhang 32

Tooldokumentation 34

Eidesstattliche Erklärung 36

Kurzfassung

Hier ist der Inhalt der Arbeit in komprimierter Form darzustellen.

Länge maximal 1 Seite.

Anmerkung:

Der Leser der Kurzfassung soll verstehen, welche Problemstellung / Fragestellung durch die vorliegende Arbeit bearbeitet wird und welche Erkenntnisse und Ergebnisse vorliegen.

Bitte beachten Sie auch die Richtlinie des Studiengangs zur Erstellung von wissenschaftlichen Arbeiten, vor allem die formalen Anforderungen wie z.B. Zitierweise nach APA-Styleguide in der Form (Autor, Jahr, Seite).

Folgende Seiten beginnen IMMER auf einer rechten, ungeraden Seite:

- Deckblatt
- Vorwort
- Inhaltsverzeichnis
- Kurzfassung
- Abstract
- Neues Kapitel auf Kapitelebene 1. Bitte fügen Sie jeweils entsprechende Leerseiten ein.

Hinweise:

- Die Masterarbeit ist doppelseitig auszudrucken.
- Beinhalten Kapitelüberschriften einen Schrägstrich, so können Sie zwischen den unterschiedlichen Überschriften wählen.

Abstract

Komprimierter Inhalt der Arbeit (Kurzfassung) in Englisch.
Länge maximal 1 Seite.

1 Einleitung

TODO

1.1 Problemstellung

Das Programmierenlernen stellt seit jeher eine erhebliche Hürde in der universitären Ausbildung dar. Wie Medeiros et al. (2019, S. 1) in der systematischen Analyse darlegen, weisen Einführungskurse in die Programmierung weltweit überdurchschnittlich hohe Durchfall- und Abbruchquoten auf. Studierende scheitern oft nicht an der Logik an sich, sondern an der kognitiven Last, die durch die Syntax formaler Sprachen und die Notwendigkeit der abstrakten Problemzerlegung entsteht. Traditionelle Lehrmethoden stoßen hier an ihre Grenzen, da sie oft nicht in der Lage sind, individuelles Feedback in der Frequenz und Tiefe zu liefern, die für das Überwinden dieser initialen Hürden notwendig wäre.

In dieses didaktische Feld treten nun Large Language Models (LLMs) wie ChatGPT, die das Potential haben, die Art und Weise, wie wir Code schreiben und lehren, fundamental zu verändern. Nach Denny et al. (2024b) stehen wir vor einem Paradigmenwechsel. Die Fähigkeit dieser Modelle ausgehend von natürlicher Sprache syntaktisch korrekten Code zu generieren, senkt zudem die Einstiegshürde drastisch (Becker et al., 2023, S. 500-501). Doch diese scheinbare Erleichterung birgt ein massives Risiko für die gute wissenschaftliche Praxis und den Kompetenzerwerb: Wenn Studierende die KI nicht als Werkzeug, sondern als Orakel nutzen, entsteht eine „Illusion of Capability"(Prather et al., 2023, S. 116). Sie produzieren Code, den sie weder verstehen noch warten können, anstatt Problemlösekompetenz zu erwerben.

Ein spezifisches Problem, das in der aktuellen Lage oft übersehen wird, ist die Diskrepanz zwischen der Generierung von isolierten Code-Schnipseln und deren Integration in bestehende, Frameworks. Während LLMs Standardalgorithmen beherrschen, zeigen Studien von Kazemitabaar et al. (2023, S. 7), dass Beginner oft daran scheitern, generierten Code korrekt in vorgegebene Strukturen einzubetten oder Kontextfehler wie z.B. halluzinierte Methodenaufrufe zu erkennen.

Die vorliegende Arbeit adressiert genau dieses Feld, indem sie untersucht, wie sich der Einsatz von ChatGPT auf die Bearbeitung einer komplexeren Aufgabe im Rahmen eines vorgegebenen Python Frameworks („Garden-Simulator“) auswirkt. Anstatt sich auf reine Performance-Metriken zu beschränken, kombiniert diese Studie eine qualitative Code-Analyse basierend auf Funktionalitäts- und Stilapekten mit einer Evaluation der User Experience mittels des User Experience Questionnaires (UEQ). Ziel ist es, evidenzbasiert zu klären, ob LLMs in der Hand von Anfängern tatsächlich zu besserer Software führen und in der Bearbeitung der Aufgabe auch bessere Usabibility-Werte erzielen können, als bei einer klassischen Durchführung ohne LLM.

1.2 Wissenschaftliche Fragestellung

Die in Kapitel 2 durchgeführte Literaturanalyse verdeutlicht im Wesentlichen zwei Aspekte: (1) Es gibt eine Vielzahl an Studien und Paper, die sich mit LLMs und Programmieren allgemein oder im engeren Sinne mit dem Einsatz von LLMs zum

Programmierenlernen beschäftigen. So fokussieren z.B. Finnie-Ansley et al. (2022) oder Kazemitabaar et al. (2023) Performance-Metriken wie Zeit, Korrektheit und Code-Qualität. Der Aspekt der User Experience bei der Interaktion mit einem LLM-Chatbot wird jedoch wenig bis selten betrachtet. Die Arbeiten von Liffiton et al. (2024), Kazemitabaar et al. (2024) und Kazemitabaar et al. (2023) nehmen hierbei eine Sonderstellung ein, da sie Einblicke in die Benutzerfreundlichkeit ihrer Tools bieten. Bei ersterem wurde eine Online-Umfrage durchgeführt, bei zweiterem Interviews sowie wöchentliche Umfragen und bei letzterem wurde Feedback mittels Likert-Skala-Fragen eingeholt. Ein standardisiertes Instrument wie der UEQ kam nicht zum Einsatz. Die Literaturanalyse verdeutlicht (2) auch, dass in Arbeiten, die den UEQ eingesetzen, es primär um die Evaluierung von LLM-Tools geht ohne spezifischen Bezug zur Programmierausbildung.

Daraus ergibt sich folgende Forschungslücke: LLM-Chatbots werden zwar als Hilfe für Programmiereinsteiger bereitgestellt, es fehlt jedoch eine standardisierte Auswertung der User Experience in diesem Bereich. Um diesem Umstand entgegenzuwirken, wird in der vorliegenden Arbeit ein LLM-Chatbot herangezogen – in diesem Fall ChatGPT – mit dessen Unterstützung das Programmieren-lernen bei Einsteigern gefördert werden soll. Dieser Prozess wird nicht nur aus didaktischer Sicht betrachtet werden, sondern auch aus dem Blickwinkel der User Experience.

Die folgenden Forschungsfragen werden im Laufe der Arbeit beantwortet:

- **RQ1:** Inwieweit beeinflusst die Nutzung eines LLMs (ChatGPT) die Leistung von ProgrammieranfängerInnen bei der Ausarbeitung einer Prüfungsaufgabe im Vergleich zu einer Bearbeitung ohne LLM?

  Gemessen wird RQ1 anhand der Faktoren: Bearbeitungszeit, Anzahl der Ausführungen bis zur Abgabe und Korrektheit der Gesamtlösung.

  Die Bewertung der Korrektheit erfordert einen detaillierten und einheitlichen Bewertungsraster, anhand dessen alle im Versuch erbrachten Programme evaluiert werden.

- **RQ2:** Wie unterscheiden sich User Experience und subjektive Wahrnehmung der Prüfungssituation zwischen den beiden Versuchsgruppen, gemessen mit dem UEQ sowie offenen Reflexionsfragen?

1.3 Methodischer Ansatz

TODO

1.4 Aufbau der Arbeit

TODO

2 Stand des Wissens / Stand der Technik

Die vorliegende Masterarbeit untersucht den Einfluss von Large Language Models (LLMs) wie ChatGPT auf das Lernen und Prüfen von Programmieranfänger*innen. Der Forschungsstand umfasst mehrere miteinander verknüpfte Bereiche: die besonderen Herausforderungen des Programmierlernens, den Einsatz von LLMs in der Programmierausbildung, deren Rolle in Prüfungs- und Bewertungsszenarien sowie didaktische Faktoren. In diesem Kapitel soll die einschlägige Literatur zusammengeführt werden.

2.1 Herausforderungen beim Programmierenlernen im tertiären Bildungsbereich

Das Erlernen von Programmierkompetenzen als besonders herausfordernd. Zahlreiche Studien zeigen, dass Einführungsveranstaltungen in der Informatik überdurchschnittlich hohe Dropout- und Durchfallsquoten aufweisen. Medeiros et al. (2019, S. 6) identifizieren in ihrer systematischen Literaturübersicht zentrale Einflussfaktoren, die den Erfolg in Einsteigerkursen bestimmen, darunter mathematische Kompetenzen, Problemlösefähigkeiten, Abstraktionsvermögen sowie die Fähigkeit, Fehlermeldungen zu interpretieren und systematisch zu debuggen. Weitere Arbeiten, etwa von Koulouri et al. (2015, S. 2) oder Gomes und Mendes (2010, S. 1), zeigen, dass insbesondere die ersten Lernschritte also das Strukturieren eines Problems und der Übergang von natürlicher Sprache zu formalen Anweisungen sowie der Umgang mit Syntax als besonders frustrierend erlebt werden.

Auf curricularer Ebene bestehen zusätzliche Herausforderungen: Lehrende müssen mit unterschiedlichen Vorkenntnisse umgehen, sinnvolle Aufgabenformate entwickeln und auf eine angemessene Balance zwischen Theorie, Codepraxis und Feedback achten. Vihavainen et al. (2014, S. 7) sowie Xinogalos (2016, S. 7-8) zeigen, dass die Wahl der Programmiersprache und der didaktischen Methode (z. B. pair programming, projektorientiertes Lernen, tutorielle Unterstützung) entscheidend dazu beiträgt, wie gut Studierende grundlegende Konzepte wie Kontrollstrukturen, Datenstrukturen oder Objektorientierung verstehen.

2.2 Die Verwendung von LLMs in der Programmierausbildung

Mit dem Aufkommen von generativen Modellen wie GPT-4, Claude oder Gemini hat sich das Programmierlernen grundlegend verändert. LLMs können Code generieren, erklären, korrigieren und optimieren. Sie können Fehlermeldungen interpretieren, Beispiele erzeugen und Lernende durch ganze Problemlösungsprozesse begleiten. Denny et al. (2024b, S. 1) beschreiben diesen Wandel als einen Paradigmenwechseln, der sowohl Chancen für individualisiertes Lernen als auch Herausforderungen für Didaktik und Prüfungsdesign mit sich bringt.

Eine Reihe von Studien befasst sich mit den unmittelbaren Lerneffekten. Finnie-Ansley et al. (2022, S. 1) sowie Kazemitabaar et al. (2024, S. 1) zeigen, dass Studierende mit LLM-Unterstützung typischerweise schneller zu funktionierenden Lösungen gelangen und weniger Frustrationspunkte erleben – insbesondere in frühen Lernphasen. Ebenso deuten mehrere Arbeiten darauf hin, dass die Fä-

higkeit der Modelle, Fehlermeldungen zu erklären Leinonen et al. (2023, S. 1), erheblich zur Reduktion von Debugging-Zeiten beiträgt.

Gleichzeitig wird in der Forschung intensiv diskutiert, ob die Nutzung solcher Systeme zu oberflächlichen Lernprozessen führt. Becker et al. (2023, S. 1) argumentieren, dass Programmieren möglicherweise nicht mehr so schwer ist wie früher, weil LLMs viele kognitive Hürden übernehmen. Damit stellt sich die Frage, welche Kompetenzen Studierende tatsächlich erwerben, wenn wesentliche Teile der Problemlösung ausgelagert werden.

Einen wichtigen Beitrag für die Praxis liefern zudem spezialisierte Systeme wie CodeHelp von Liffiton et al. (2024, S. 1) oder CodeAid von Kazemitabaar et al. (2024, S. 3), die LLMs mit didaktischen Leitplanken kombinieren. Diese Tools verhindern, dass der User direkt eine Code-Lösung erhält. Sie bieten stattdessen erklärende Unterstützung, wodurch eigenständiges Denken angeregt werden soll. Erste Studien zu CodeAid und ähnlichen Classroom-Assistenten belegen, dass LLMs in realen Kursen bereits als standardisierte Unterstützungswerkzeuge eingesetzt werden können – allerdings nur, wenn klare Regeln zur Nutzung definiert werden.

2.3 Generative KI in Prüfungen und Bewertungsszenarien

Der Einsatz von LLMs stellt traditionelle Prüfungsformate grundlegend infrage. Studien wie die von Pinto et al. (2023, S. 6) zeigen, dass LLMs offene Fragen in vielen Fällen ähnlich wie menschliche Bewertende beurteilen können - allerdings mit typischen Abweichungen: Manche Modelle sind strenger, andere übersehen subtile Fehler. Damit wird die Frage nach Fairness, Reliabilität und Transparenz solcher Bewertungsmethoden zentral.

Parallel dazu diskutieren Denny et al. (2024a, S. 1), Mahon et al. (2024, S. 1) und Prather et al. (2023, S. 108), welche Aufgabenformate noch geeignet sind, individuelle Kompetenzen im LLM-Zeitalter zu prüfen. Aufgaben, die primär auf reiner Codeproduktion beruhen, verlieren an Aussagekraft, da LLMs solche Lösungen oft vollständig generieren. Stärker gefragt sind daher Problemanalyse, Codebewertung, Fehlersuche, Designentscheidungen und das Verfassen erklärender Texte. Diese Komponenten gelten als „LLM-resistent“, weil sie Verständnis und Reflexion voraussetzen und nicht vollständig automatisierbar sind.

2.4 LLM-unterstütztes Programmierenlernen

Mehrere kontrollierte Studien untersuchen, wie sich der Einsatz großer Sprachmodelle auf das Programmierlernen von Anfänger:innen auswirkt. Eine häufig zitierte Arbeit stammt von Kazemitabaar et al. (2023, S. 11): In einem randomisierten Experiment mit 69 Beginner:innen zeigte sich, dass Lernende mit Zugriff auf einen Codex-basierten Code-Generator signifikant häufiger funktionsfähige Programme erzeugten und ihre Aufgaben schneller lösten als die Kontrollgruppe. Gleichzeitig blieben ihre Leistungen bei nachfolgenden manuellen Code-Modifikationen stabil, was ein Hinweis darauf ist, dass der Einsatz von LLMs nicht automatisch zu Abhängigkeit führt.

Eine weitere Analyse von Kazemitabaar et al. (2023, S. 1) liefert Aufschluss über

die Interaktionsmuster von Programmier-Einsteiger*innen bei der Verwendung von OpenAIs Codex. Anhand von Log-Daten identifizierten die Autoren vier distinkte Nutzungsstrategien bei Novizen: „AI Single Prompt“ (Generierung der gesamten Lösung), „AI Step-by-Step“, „Hybrid“ und „Manual“. Die Ergebnisse deuten darauf hin, dass die Art der Interaktion entscheidend für den nachhaltigen Lernerfolg ist: Der „Hybrid“-Ansatz, der eine Mischung aus eigenständigem Schreiben und gezielter KI-Nutzung darstellt, zeigte positive Trends hinsichtlich der Ergebnisse in späteren Retention-Tests. Wohingegen der „AI Single Prompt“-Ansatz eher mit negativen Resultaten korrelierte. Dies unterstreicht, dass der didaktische Mehrwert von LLMs maßgeblich vom Grad der Selbstregulation (Self-Regulation) und der eigenen kognitiven Beteiligung abhängt (Kazemitabaar et al., 2023, S. 12).

Xue et al. (2024, S. 3-6) untersuchten den Einsatz von ChatGPT 3.5 in einem CS1-Java-Kurs. Obwohl ChatGPT syntaktische Fehler reduzieren konnte, zeigten sich keine signifikanten Vorteile in tiefergehenden konzeptuellen Aufgaben. Die Autor:innen betonen, dass LLMs ohne didaktische Einbettung nur begrenzt Lernzuwächse erzeugen. Ein weiteres Experiment von Toba et al. (2024, S. 6-8) demonstriert vor allem Effizienzgewinne: Mit ChatGPT lösten Studierende Programmieraufgaben etwa doppelt so schnell wie ohne. Die Codequalität blieb jedoch vergleichbar. Gleichzeitig weist die Studie auf Risiken wie missbräuchliche Nutzung in Prüfungssituationen hin.

Eine systematische Meta-Analyse von Alanazi et al. (2025, S. 12-15) bestätigt diese Befunde: KI-gestützte Lernsettings verbessern im Durchschnitt Performance und Bearbeitungszeit deutlich, zeigen aber keine konsistenten Effekte auf tiefes Konzeptverständnis.

2.5 User-Experience-Messungen von LLM-Chatbots mittels User Experience Questionnaires (UEQ)

Die Evaluierung von LLM-basierten Chatbots erfordert Messinstrumente, die über reine Leistungsmetriken hinausgehen und die subjektive Wahrnehmung der Interaktion erfassen. Als Standardinstrument hat sich hierbei der User Experience Questionnaire (UEQ) etabliert, da er sowohl pragmatische (zielgerichtete) als auch hedonische (nicht-zielgerichtete) Qualitätsaspekte abdeckt (Schrepp, 2023, S. 2-3).

Aktuelle Studien bestätigen die Eignung dieses Messinstruments für Chatbots: So konnten Mendoza et al. (2022, S. 17) in einer Untersuchung im schulischen Umfeld nachweisen, dass der UEQ verlässliche Aussagen über die Akzeptanz von Lernassistenten liefert, wobei insbesondere die Dimensionen der Effizienz und der Verlässlichkeit (Efficieny und Dependability) als kritische Erfolgsfaktoren identifiziert wurden. Ambacher (2024) hebt in seiner Analyse von LLM-User-Interfaces hervor, dass eine mangelnde Transparenz über die Funktionsweise des Modells oder unerwartetes Systemverhalten direkt die Dimenson Verlässlichkeit negativ beeinflusst. Wird das System als unberechenbar wahrgenommen, sinkt die Akzeptanz, selbst wenn die generierten Antworten technisch hilfreich sein könnten. Demgegenüber verweist Shahu et al. (2025, S. 6) auf das Potential von LLMs, die pragmatische Qualität (Effizienz, Verständlichkeit und Verlässlichkeit) einer Aufgabe oder eines Produkts stark zu steigern. Ihre Arbeit handelt von einem GIS-Assistenten namens MMapGPT", der durch Implementierung natür-

lichsprachlicher Eingaben die Barrieren zur Nutzung dieser komplexer Software senken konnte. Dieser Sachverhalt schlug sich in positiven Werten auf den UEQ-Skalen für Efficiency (Effizienz) und Perspicuity (Verständlichkeit) nieder. Lee et al. (2024, S. 5-6) verwendeten auch den UEQ als Messinstrument für die Evaluierung ihres Chatbots ChatFiveünd konnten in der Dimension Attraktivität sowie dem Bereich Stimulation signifikant höhere Werte erzielen.

Folglich erweist sich der UEQ als das methodisch adäquate Instrument, um nicht nur die funktionale Gebrauchstauglichkeit (Pragmatik), sondern auch die durch generative KI neu entstehenden emotionalen Interaktionsqualitäten (Hedonik) in einem erprobten Messmodell vergleichbar zu erfassen.

2.6 Zusammenfassung

TODO

3 Forschungsmethodik

3.1 Motivation & Zielsetzung

3.2 Studiendesign und Versuchsaufbau

3.3 Erläuterung der Erhebungsinstrumente: persönlicher Fragebogen und UEQ

3.4 Konzeption der Programmieraufgabe: Das „Garden-Simulator“-Framework

Nach dem persönlichen Fragebogen und nachdem die Entwicklungsumgebung bereitsteht, soll die Programmieraufgabe von den Studierenden bearbeitet werden. Dieses Kapitel behandelt den Aufbau und Hintergrund des Python-Programms „Garden-Simulator“, die Aufgabenerstellung sowie die erwarteten Lösungen und die Testumgebung.

3.4.1 Der „Garden-Simulator“

Der Garden sim

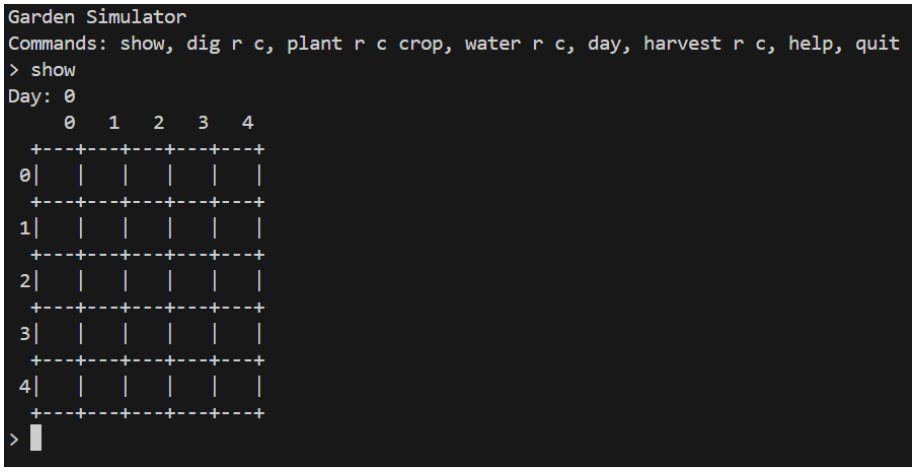


Abbildung 3.1: Startansicht des Garden-Simulators mit ausgeführtem show-Befehl

3.4.1.1 README.md als Informationsquelle

3.4.2 Programmstruktur des „Garden-Simulators“

Funktional bildet der Simulator einen festgelegten Handlungszyklus ab: Zuerst wird ein Feld gegraben, anschließend bepflanzt, danach regelmäßig gegossen, die Zeit wird tageweise fortgeschritten und schließlich kann geerntet werden. Die Ausgabe erfolgt im Terminal als leicht lesbares Raster mit einfachen Symbolen, ergänzt um Zeilen- und Spaltenindizes, damit Interaktionen über Koordinaten nachvollziehbar bleiben.

Diese Regeln sind in einer Zustandslogik definiert:

- Graben ist nur auf leeren Feldern möglich und erzeugt ein „hole“

- Pflanzen ist ausschließlich auf einem „hole“ erlaubt und erzeugt ein „seed“
- Gießen ist nur bei „seed“ oder „sprout“ zulässig und erhöht den Wasserstand bis zu einem Maximalwert
- Das Fortschreiten eines Tages wirkt auf alle Zellen gleichzeitig. Der Wasserstand wird pro neuem Tag um 1 verringert.
- Ernten ist wiederum nur im Zustand „ripe“ möglich

Die in Abb. 3.2 gezeigte Repository-Struktur trennt klar zwischen Kernlogik, Darstellung und Interaktion. In garden.py liegt die zentrale Logik als Sammlung von Funktionen; dort werden gezielt Stubs mit Docstrings, Kommentaren und Beispielen bereitgestellt, die zunächst noch nicht implementiert sind und teils NotImplementedError auslösen. In cli_view.py befindet sich eine vorgegebene, von Studierenden nicht zu verändernde Hilfsklasse (GardenPrinter), die den Garten ausschließlich liest und als Text darstellt; dadurch wird eine konsistente Visualisierung sichergestellt, ohne dass Studierende bereits objektorientierte Konzepte benötigen. main.py stellt eine einfache Kommandozeilen-Interaktion bereit, in der Befehle wie `dig r c`, `plant r c crop`, `water r c`, `day`, `harvest r c` oder `show` eingegeben werden können. Das Parsing erfolgt bewusst mit String split und if/else, um den Fokus auf Kontrollstrukturen, Zustandsprüfungen und Datenmanipulation zu legen.



Abbildung 3.2: Repository-Aufbau des „Garden-Simulators“

In test_garden.py sind unter Zuhilfenamhe des pytest-Frameworks Unit-Tests hinterlegt, die für jede Funktion konkret festlegen, welches Verhalten erwartet wird wie z. B. erlaubte Zustandswechsel, Rückgabewerte oder out-of-bounds-Fälle. Für Studierende dienen diese Tests als verlässliche Referenz, weil sie nach jeder Implementationsänderung sofortiges, objektives Feedback liefern und typische Fehler klar sichtbar machen. Gleichzeitig bilden die Tests eine transparente Grundlage für die Auswertung. Wenn das Programm alle Tests besteht, erfüllt es Level 4 der Kategorie „Funktionaliät und Robustheit“ des Bewertungsrasters in Tabelle 3.1.

3.4.3 Erstellung der Aufgaben nach UMC-Framework

Als Programmieraufgabe sollen die Studierenden in der bestehenden Python CLI-Anwendung *Garden-Simulator* bestimmte Use Cases implementieren. Das didaktische Design dieser Unterrichtseinheit basiert auf dem Use-Modify-Create (UMC) Framework, wie es ursprünglich von Lee et al. (2011) definiert wurde. Em-

pirische Studien, wie die von Lytle et al. (2019, S. 400) zeigen, dass dieser Ansatz insbesondere ab der Modify-Phase zum einen die Identifikation mit dem selbst geschriebenen Code (Ownership) stärkt. Zum anderen und für diese Arbeit wichtiger wird auch die Überforderung bzw. die kognitve Last auf Studierendenseite reduziert.

Die Programmieraufgabe ist in die drei Phase des UMC-Frameworks aufgeteilt. In der ersten Phase (Use) geht es um das Kennenlernen und Ausführen des Source Codes. Im Fall des Garden-Simulators sollen auch einfach Commands in das Command Line Interface (CLI) eingegeben und ausgeführt werden. Die zweite Phase fordert von den Studierenden, den in Phase 1 genutzten Code iterativ anzupassen. Um den Code gezielt zu verändern, muss auf Seite der Studierenden zumindest Teile der inneren Logik durchdrungen worden sein. Die dritte und finale Phase besteht aus der Erweiterung des bestehenden Artefakts. Die Studierenden fügen hier weitesgehend eigenständig eine neue Funktion hinzu. Was zu implemtieren ist, wird aufgrund der begrenzten Zeit verbal vorgegeben, auf eine zu detaillierte Aufgabenbeschreibung oder Hinweise im Code wurden jedoch verzichtet. (Lee et al., 2011).

Die folgenden Aufgaben sind von den Studierenden zu implementieren.

1. Führe den `help` command aus und sehe dir die Liste an Commands an. Gehe einen Harvest-Zyklus für das Crop „tomato“ in der CLI durch. Führe dafür folgende Commands aus: `dig`, `plant`, `water`, `day`, `water`, `day`, `water`, `day`, `harvest`.
2. Für den Command `quit` fehlt die Beschreibung im help-Befehl. Füge
   i. „quit“ als Command-Name hinzu,
   ii. „Exit the simulator“ als Beschreibung und
   iii. „quit“ als Beispiel.
3. Wenn eine Tomate geerntet wird, wird eine Datei names tomato.txt erstellt. Der User soll über das Erstellen der tomato.txt informiert werden. Der Satz „Created file 'tomato.txt' at <current datetime>“ soll in der Konsole ausgegeben werden. Die Aufgabe ist im Code mittels Kommentarblöcken markiert.
   Beispiel:
   `Created file 'tomato.txt' at 18.05.2026 18:36:22.`
4. Wenn keine Tomate geerntet wird, soll bei den anderen Crops in der Konsole der Satz ausgegeben werden: „[Info] The crop <name of the crop> has no file entry.“
   Beispiel:
   `[Info] The crop carrot has no file entry.`
5. Füge ein neues Crop „potato“ hinzu. Man soll es schon nach 2 `water` + `day` Zyklen ernten können. Die Aufgabe ist im Code nicht mittels Kommentarblöcken markiert. Es müssen dazu Änderungen in beiden Dateien main.py und garden.py gemacht werden.

3.4.4 Musterlösung der Aufgaben und Programmierkonzepte

TODO, todo

3.4.5 Lokale Tests zur Selbstüberprüfung

Um herauszufinden, ob die jeweilige Teilaufgabe korrekt erledigt wurde, können die Studierenden mittels des Commands `python test_runner.py` lokale Tests ausführen. Ein Report über bestandene und nicht bestandene Testcases, wie in Abb. 3.3 dargestellt, wird im Terminal präsentiert. Die Tests sollen den Programmier-Prozess der Studierenden unterstützen und so einerseits die korrekte Erledigung einer Aufgabe validieren und andererseits als Debugging-Instrument dienen. Letzteres, also das Lösen einzelner Probleme oder Fehler im Code, ist nach Edwards (2004, S. 26) ProgrammiereinsteigerInnen besonders zeitintensiv und resultiert oft in wahllosen Herumprobieren. Idealerweise sollten die Tests von den Studierenden im Rahmen des Test Driven Developments selbst verfasst werden (Edwards, 2004, S. 27–28; Janzen & Saiedian, 2008, S. 532–533). In der vorliegenden Arbeit werden die Tests hingegen aufgrund der begrenzten Bearbeitungszeit bereitgestellt.

```
@TobiWilhelm ➜/workspaces/garden-simulator (feature/test-runner-validation) $ python test_runner.py
======================================================================
GARDEN SIMULATOR - ASSIGNMENT TESTS
======================================================================
Running 6 required tests...

[FAIL] Task 1: Complete tomato harvest cycle in the CLI (0.00s)
       The file harvests/tomato.txt does not exist.
[PASS] Task 2: Add quit to the help table (0.03s)
[FAIL] Task 3: Print the tomato file creation message (0.00s)
       The required timestamped file creation message was not printed.
[FAIL] Task 4: Print the non-tomato information message (0.00s)
       The required information message for bean was not printed.
[FAIL] Task 5: Grow potato in two cycles (0.00s)
       potato is missing from main.py CROPS.
[PASS] Task 5: Keep carrot growth at three cycles (0.00s)

----------------------------------------------------------------------
TESTS FAILED: 4  |  PASSED: 2/6
Review the messages above, update your code, and run the tests again.
----------------------------------------------------------------------
```

Abbildung 3.3: Ausgabe des lokalen Testrunners bei fehlgeschlagenen und bestandenen Tests

Wie in Abb. 3.3 zu sehen ist, gibt es für jede Teilaufgabe einen eigenen Test. Als Hilfestellung und um den Testcase zu konkretisieren wird bei jedem fehlgeschlagenen Testcase ein Statustext ausgegeben. So wird z.B. für die nicht erfüllte Teilafgabe drei ausgegeben: „The required timestamped file creation message was not printed." Für Teilaufgabe fünf gibt es jedoch zwei Tests. Denn, wie in der Aufgabenstellung in 3.4.3 erwähnt, müssen hier die benötigten `day`- und `water`-Zyklen bis zur Erntereife für das Crop `potato` adaptiert werden. Es kann hierbei aber passieren, dass die Zyklenanzahl auch für andere Crops verändert wird. Daher wird im letzten Testcase überprüft, ob für ein anderes Crop, in diesem Fall `carrot`, weiterhin die regulären drei `day`- und `water`-Zyklen bis zur Reife erforderlich sind.

3.5 Bewertungsraster zur Evaluierung der Programmieraufgabe

Zur Bewertung der Ausarbeitungen der ProbandInnen wird ein analytisches Bewertungsraster (Rubric) verwendet, das primär auf dem evidenzbasierten Modell von (Stegeman et al., 2016) basiert. Dieses Instrument wurde spezifisch für das Feedback in Einführungskursen der Programmierung (CS1) entwickelt und folgt dem Ansatz eines *Instructional Rubric*. Ziel eines solchen Bewertungsrasters ist es zum einen eine summative Note zu generieren. Zum anderen auch dem Ler-

nenden die Lücke zwischen der aktuellen Leistung und der erwarteten Qualität transparent zu machen. Im Falle der Studie ist der erste Aspekt ausschlaggebend.

Kategorie	**Gewichtung**	**Level 1 (Problematisch)**	**Level 2 (Kernziele nicht erreicht)**	**Level 3 (Kernziele erreicht)**	**Level 4 (Kernziele übertroffen)**
Funktionalität & Robustheit	0.45	Runtime Errors, grundlegende Anwendungsfälle funktionieren nicht	Ein Teil der Anforderungen ist korrekt implemntiert, bei anderen treten Laufzeitfehler oder falsche Ergebnisse auf oder sind nicht implementiert	Alle Anforderungen werden erfüllt inklusive positver Tests	Zusätzlich zu Level 3 ist der Code robust gegen Randfälle und ungültigen Eingaben
Namen	0.10	Unklare oder irreführende Namen	Namen beschreiben ihren Zweck grunsätzlich zutreffend. Sie weisen aber inkonsistente Schreibweisen auf, sind fehlerhaft geschrieben oder sehr lang	Namen beschreiben ihren Zweck treffend. Konsistentes snake_case, korrekt geschrieben	Zusätzlich zu Level 3 wird im gesamten Programm ein einheitliches Vokabular zur Namensgebung verwendet
Layout & Formatierung	0.10	Erschwerte Lesbarkeit durch eine zu lange Zeilenlänge, falsche Einrückungen oder zurückgelassenen auskommentierten Code	Beabsichtigte Struktur ist grundsätzlich erkennbar. Inkonsistente Formatierung ähnlicher Blöcke	Konsistente Einrückung und Struktur. Zeilenlängen unterstützen die Lesbarkeit	Vollständig PEP 8 konform. Code-Elemente sind einheitlich formatiert und auch über mehrere Dateien konsitent positioniert.
Kontrollfluss	0.15	Verschachtelung > 7 Ebenen, unerreichbarer Code, mehrere Anweisungen pro Zeile	Verschachtelung > 5 Ebenen, viele Sprünge (continue, break oder return), entählt doppelten Code	Einfacher Kontrollfluss, wenige Sonderfälle oder Sprünge, begrenzte Codeduplikation	Zusätzlich zu Level 3 bleibt der häufigste Ausführungspfad auch bei Sonderfällen oder Sprüngen klar erkennbar.
Idiomatische Programmie-rung	0.10	Kontrollstrukturen werden zweckentfremdet oder irreführend nachgebildet	Unangemessene Wahl der Kontrollstruktur für die jeweilige Aufgabe	Angemessene Wahl der Kontrollstruktur. Verwendung von Bibliotheksfunktionen kann noch begrenzt sein	Zusätzlich zu Level 3 werden Bibliotheksfunktionen und Standard-Datenstrukturen umfassend verwendet.
Aufteilung in Funktionen	0.10	Monolithischer Code, Variablen werden für unterschiedliche Zwecke wiederverwendet lange unübersichtliche Funktionen	Funktionen sind in ihrer Länge begrenzt, vermischen aber unterschiedliche Aufgaben	Funktionen bearbeiten eine überschaubare Menge von Aufgaben mit nachvollziehbarer interner Gliederung	Zusätzlich zu Level 3 bearbeiten Funktionen eine eng abgegrenzte Aufgabe. Geringe Parameterzahl und begrenzte Zahl gemeinsam genutzter Variablen.

Tabelle 3.1: Bewertungsraster V2 nach (Stegeman et al., 2016)

Das Raster (Abb. 3.1) bewertet die Code-Qualität anhand von sechs Eigenschaften. Es unterteilt die erbrachte Leistung in vier Erfüllungsgrade. Eine Einordnung in Level 1 bedeutet, dass in dieser Kategorie problematische Teile vorhanden sind. In Level 2 sind die zentralen Kernziele nicht ganz erreicht, es wurde jedoch Code produziert, der keine problematischen Elemente mehr enthält. Ab Level 3 sind die Kernziele erreicht und in Level 4 sogar darüber hinaus. Den Bewertungsstufen werden folgende Punkte zugeordnet: Level 1 entspricht 10 Punkten, Level 2 entspricht 20 Punkten, Level 3 entspricht 30 Punkten und Level 4 entspricht 40 Punkten.

Die einzelnen Leistungsanforderungen sind in Tabelle 3.1 aufgeschlüsselt. Die Kategorien des Rasters wurden aus dem iterativen Design-Prozess für Bewertungsraster von (Stegeman et al., 2016) abgeleitet. Die validierten Kriterien Namen (*names*), Layout & Formatierung (*layout/formatting*), Kontrollfluss (*flow*), Idiomatische Programmierung (*idiom*) und Aufteilung in Funktionen (*decomposition*) werden für den Bewertungsraster der vorliegenden Arbeit adaptiert. So wurden die im Paper ursprünglich für C und Swift entwickelten Deskriptoren für den Kontext der Sprache Python angepasst. Hervorzuheben ist hierbei snake_case für Variablennamen gemäß PEP 8[1].

Zudem wird für die Kategorie Kontrollfluss die Kennzahl Verschachtelung auf Level 1 definiert als mehr als sieben ineinanderfolgende Kontrollstrukturen innerhalb einer Funktion. Auf Level 2 werden Verschachtelungen von mehr als 5 Ebenen eingeordnet. Dabei werden Verzweigungen und Schleifen gemeinsam gezählt. Dieser Schwellenwert orientiert sich am Standardwert für das Attribut *max-nested-blocks* mit dem Wert fünf aus der Pylint-Dokumentation[2].

3.5.1 Ergänzung der Dimension „Funktionalität und Robustheit“

Das Modell von (Stegeman et al., 2016) fokussiert sich explizit auf die Code Qualität wie Lesbarkeit, Wartbarkeit und Struktur, die funktionale Korrektheit ist ausklammert. Um jedoch einen umfassendere Bewertung der Abgaben zu gewährleisten, werden Abgaben einer Überprüfung der Laufzeit-Korrektheit unterzogen. Daher wurde das Raster um die Kategorie FFunktionalität & Robustheitërweitert. Diese Kategorie folgt dem Konzept der vier Erfüllungsgrade aus (Stegeman et al., 2016) und wendet sie auf das Laufzeitverhalten an: Level 1 markiert instabilen Code (Abstürze/Runtime Errors), Level 2 funktional falsche Ergebnisse (Logic Errors), Level 3 die korrekte Erfüllung der Spezifikation (Happy Path) und Level 4 eine erhöhte Robustheit gegenüber Randfällen (Edge Cases).

Der Kategorie vorgeschaltet ist Überprüfung der Ausführbarkeit: Code, der aufgrund von Syntaxfehlern nicht vom Interpreter verarbeitet werden kann, fürht dazu dass die Abgabe ein Level abrutscht.

[1] Link zum Python-Styleguide PEP 8: https://peps.python.org/pep-0008/
[2] Link zur Pylint-Dokumentation: pylint

3.6 Planung der Pilotstudie

3.7 Diskussion

3.8 Zusammenfassung

4 Evaluierung der Studie

4.1 Pilotphase der Studie

Bevor die Studierenden mit der Studie konfrontiert werden sollten, wurden die Aufgaben und Abläufe in der Pilotphase erprobt. Die Pilotphase wurde mit insgesamt 3 Personen druchgeführt. Die Auswahl erfolgte aufgrund ihrer Eigenschaften, welche Überschneidungen im Bereich Alter, Studienrichtung oder Vorwissen im Vergleich zur Studiengruppe aufweisen. Im Folgenden sind die Eckdaten der Personen aufgelistet, die die Pilotphase durchlaufen sind:

Person A: 30 Jahre, männlich, Bachelorstudent im Bereich Cloud und IT. Programmierkenntnisse: Gerning. Erfahrung mit Python: Gering

Person B: 28 Jahre, männlich, Bachelorstudent für Lehramt Informatik. Programmierkenntnisse: Mittel. Erfahrung mit Python: Gering

Person C: 26 Jahre, weiblich, Lehrabschluss IT-Technik, Programmierkenntnisse: Gering. Erfahrung mit Python: Gering

Zur Einarbeitung der Verbesserungen wurde ein inkrementelle bzw. agiler Ansatz gewählt. So wurden die drei Personen auch nicht an einem Tag zur Pilotstudie eingeladen. Die Termine wurden mit den Personen nacheinander arrangiert, damit zwischen den Durchführungen genug Zeit vorhanden war, um die Studie anzupassen. Um diese inkrementellen Anpassungen soll es im nun folgenden Kapitel gehen. Es soll auf die Teilaspekte Aufgabenstellung, Entwicklungsumgebung, Quellcode und Bewertungsraster eingeangen weden.

4.1.1 Durchführung und Erkenntnisse der Pilotstudie

Die Termine mit den Personen in der Pilotphase wurden online über Discord abgehalten. Die Versuchspersonen wurden von Anfang an gebeten den Bildschirm freizugeben, damit auch die Schritte vor der Bearbeitung der Aufgaben nachvollzogen weden können.

4.1.1.1 Durchführung mit Person A

Vor dem Termin mit Person A entstand eine rudimentäre Checkliste, die den allgemeinen Ablauf der Studie festhaltet. Die Aufgabenstellung bestand derzeit aus vier Aufgaben mit dem Aufgabenprofil (Aufgabennummer - Klassifikation nach UMC-Framework - Schwierigkeitsgrad): Aufgabe 1 - use - einfach, Aufgabe 2 - modify - einfach, Aufgabe 3 - modify - einfach/mittel, Aufgabe 4 - create/modify - schwer. Person A hat die Aufgaben lokal am persönlichen Windows-11-PC in der Entwicklungsumgebung VS Code bearbeitet. Python war bereits installiert.

Ein zentrales Thema, das während der Durchführung mit Person A auffiel, war die Entwicklungsumgebung. In der Hauptstudie galt das *Bring Your Own Device* - Prinzip und somit musste sichergestellt werden, dass alle TeilnehmerInnen dieselbe Ausgangslage haben. Zwei Lösungsmöglichkeiten wurden im Anschluss diskutiert. Einerseits die Bereitstellung eines vorkonfigurierten Abbilds einer virtuellen Maschine, das mit allen zur Bearbeitung notwendigen Werkzeugen an die Studierenden verteilt werden kann. Andererseits wurde die Verwendung von

GitHub Codespaces in Betracht gezogen, das ebenfalls zentral konfiguriert werden kann, jedoch eine cloudbasierte Lösung darstellt. Ein Codespace wird über den Browser aus einem GitHub-Repository heraus gestartet und man erhält in einem neuen Tab eine VS-Code-Webclient-Oberfläche. Die Entwicklungsumgebung läuft in einem Entwicklungscontainer, genannt DevContainer. Dieser wird über die Datei *devcontainer.json*, die sich im Ordner *.devcontainer* im Repository befindet, konfiguriert. Als Konfigurationsmöglickeiten können unter anderem die benötigten Werkzeuge, Laufzeitumgebungen sowie VS-Code-Erweiterungen und Einstellungen festgelegt werden.

ZIT: https://docs.github.com/en/codespaces/setting-up-your-project-for-codespaces/adding-a-dev-container-configuration/introduction-to-dev-containers

Zusammengefasst fanden in dieser anfänglichen Phase des Pilots die Erstellung der Checkliste sowie die erstmalige Evaluierung des Bewertungsrasters statt. Zudem wurde die zentrale Frage nach der Programmierumgebung aufgeworfen.

4.1.1.2 Durchführung mit Person B

Einen Tag nach Person A wurde mit Person B der Pilot durchgeführt. Die größte Änderung im Vergleich zu

4.1.1.3 Durchführung mit Person C

4.1.2 Adaptionen für die Hauptstudie

4.2 Hauptstudie

4.2.1 Evaluierung

4.3 Auswertung Fragebogen 1 und UEQ (Fragebogen 2)

4.3.1 Fragebogen 1 - Selbsteinschätzung der ProbandInnen

4.3.2 UEQ

4.4 Diskussion

4.5 Zusammenfassung

5 Diskussion & Interpretation

Auf Forschungsfragen eingehen

6 Conclusio

Literaturverzeichnis

Alanazi, M., Soh, B., Samra, H., & Li, A. (2025). The Influence of Artificial Intelligence Tools on Learning Outcomes in Computer Programming: A Systematic Review and Meta-Analysis. https://doi.org/10.3390/computers14050185

Ambacher, J. E. (2024). *Designing a user-friendly and optimized version of a user interface for a large language model (LLM)*. Technische Hochschule Ingolstadt. http://nbn-resolving.de/urn:nbn:de:bvb:573-51556

Becker, B. A., Denny, P., Finnie-Ansley, J., Luxton-Reilly, A., Prather, J., & Santos, E. A. (2023). Programming Is Hard - Or at Least It Used to Be: Educational Opportunities and Challenges of AI Code Generation. *Proceedings of the 54th ACM Technical Symposium on Computer Science Education V. 1*, 500–506. https://doi.org/10.1145/3545945.3569759

Beispiel, A. (2024). Neue Erkenntnisse in der Forschung. *Journal of Research*, *15*(3), 123–145.

Denny, P., Leinonen, J., Prather, J., Luxton-Reilly, A., Amarouche, T., Becker, B. A., & Reeves, B. N. (2024a). Prompt Problems: A New Programming Exercise for the Generative AI Era. *Proceedings of the 55th ACM Technical Symposium on Computer Science Education V. 1*, 296–302. https://doi.org/10.1145/3626252.3630909

Denny, P., Prather, J., Becker, B. A., Finnie-Ansley, J., Hellas, A., Leinonen, J., Luxton-Reilly, A., Reeves, B. N., Santos, E. A., & Sarsa, S. (2024b). Computing Education in the Era of Generative AI. *Commun. ACM*, *67*(2), 56–67. https://doi.org/10.1145/3624720

Edwards, S. H. (2004). Using software testing to move students from trial-and-error to reflection-in-action. *ACM SIGCSE Bulletin*, *36*(1), 26–30. https://doi.org/10.1145/1028174.971312

Finnie-Ansley, J., Denny, P., Becker, B. A., Luxton-Reilly, A., & Prather, J. (2022). The Robots Are Coming: Exploring the Implications of OpenAI Codex on Introductory Programming. *Proceedings of the 24th Australasian Computing Education Conference*, 10–19. https://doi.org/10.1145/3511861.3511863

Gomes, A. J., & Mendes, A. J. (2010). A study on student performance in first year CS courses. *Proceedings of the Fifteenth Annual Conference on Innovation and Technology in Computer Science Education*, 113–117. https://doi.org/10.1145/1822090.1822123

Janzen, D., & Saiedian, H. (2008). Test-driven learning in early programming courses. *Proceedings of the 39th SIGCSE technical symposium on Computer science education*, 532–536. https://doi.org/10.1145/1352135.1352315

Kazemitabaar, M., Chow, J., Ma, C. K. T., Ericson, B. J., Weintrop, D., & Grossman, T. (2023). Studying the effect of AI Code Generators on Supporting Novice Learners in Introductory Programming. *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. https://doi.org/10.1145/3544548.3580919

Kazemitabaar, M., Hou, X., Henley, A., Ericson, B. J., Weintrop, D., & Grossman, T. (2023). How Novices Use LLM-based Code Generators to Solve CS1 Coding Tasks in a Self-Paced Learning Environment. *Proceedings of the 23rd Koli Calling International Conference on Computing Education Research*, 1–12. https://doi.org/10.1145/3631802.3631806

Kazemitabaar, M., Ye, R., Wang, X., Henley, A. Z., Denny, P., Craig, M., & Grossman, T. (2024). CodeAid: Evaluating a Classroom Deployment of an LLM-based Programming Assistant that Balances Student and Educator Needs. *Proceedings of the CHI Conference on Human Factors in Computing Systems*. https://doi.org/10.1145/3613904.3642773

Konferenz, P. (2024). Innovative Ansätze in der Technik. *Proceedings of the International Conference on Technology*, 67–89.

Koulouri, T., Lauria, S., & Macredie, R. D. (2015). Teaching Introductory Programming: A Quantitative Evaluation of Different Approaches. *ACM Trans. Comput. Educ.*, *14*(4). https://doi.org/10.1145/2662412

Lee, I., Martin, F., Denner, J., Coulter, B., Allan, W., Erickson, J., Malyn-Smith, J., & Werner, L. (2011). Computational thinking for youth in practice. *ACM Inroads*, *2*(1), 32–37. https://doi.org/10.1145/1929887.1929902

Lee, J., Choi, Y., Song, M., & Park, S. (2024). ChatFive: Enhancing User Experience in Likert Scale Personality Test through Interactive Conversation with LLM Agents. *Proceedings of the 6th ACM Conference on Conversational User Interfaces*. https://doi.org/10.1145/3640794.3665572

Leinonen, J., Hellas, A., Sarsa, S., Reeves, B., Denny, P., Prather, J., & Becker, B. A. (2023). Using Large Language Models to Enhance Programming Error Messages. *Proceedings of the 54th ACM Technical Symposium on Computer Science Education V. 1*, 563–569. https://doi.org/10.1145/3545945.3569770

Liffiton, M., Sheese, B. E., Savelka, J., & Denny, P. (2024). CodeHelp: Using Large Language Models with Guardrails for Scalable Support in Programming Classes. *Proceedings of the 23rd Koli Calling International Conference on Computing Education Research*. https://doi.org/10.1145/3631802.3631830

Lytle, N., Cateté, V., Boulden, D., Dong, Y., Houchins, J., Milliken, A., Isvik, A., Bounajim, D., Wiebe, E., & Barnes, T. (2019). Use, Modify, Create: Comparing Computational Thinking Lesson Progressions for STEM Classes. *Proceedings of the 2019 ACM Conference on Innovation and Technology in Computer Science Education*, 395–401. https://doi.org/10.1145/3304221.3319786

Mahon, J., Mac Namee, B., & Becker, B. A. (2024). Guidelines for the Evolving Role of Generative AI in Introductory Programming Based on Emerging Practice. *Proceedings of the 2024 on Innovation and Technology in Computer Science Education V. 1*, 10–16. https://doi.org/10.1145/3649217.3653602

Medeiros, R. P., Ramalho, G. L., & Falcão, T. P. (2019). A Systematic Literature Review on Teaching and Learning Introductory Programming in Higher Education. *IEEE Transactions on Education*, *62*(2), 77–90. https://doi.org/10.1109/TE.2018.2864133

Mendoza, S., Sánchez-Adame, L. M., Urquiza-Yllescas, J. F., González-Beltrán, B. A., & Decouchant, D. (2022). A Model to Develop Chatbots for Assisting the Teaching and Learning Process. *Sensors*, *22*(15). https://doi.org/10.3390/s22155532

Mustermann, M. (2023). *Grundlagen der Forschung*. Verlag.

Online, S. (2024). *Digitale Transformation in der Forschung*. Verfügbar 15. Januar 2024 unter https://example.com/digital-transformation

Pinto, G., Cardoso-Pereira, I., Monteiro, D., Lucena, D., Souza, A., & Gama, K. (2023). Large Language Models for Education: Grading Open-Ended Questions Using ChatGPT. *Proceedings of the XXXVII Brazilian Symposium on Software Engineering*, 293–302. https://doi.org/10.1145/3613372.3614197

Prather, J., Denny, P., Leinonen, J., Becker, B. A., Albluwi, I., Craig, M., Keuning, H., Kiesler, N., Kohn, T., Luxton-Reilly, A., MacNeil, S., Petersen, A., Pettit, R., Reeves, B. N., & Savelka, J. (2023). The Robots Are Here: Navigating the Generative AI Revolution in Computing Education. *Proceedings of the 2023 Working Group Reports on Innovation and Technology in Computer Science Education*, 108–159. https://doi.org/10.1145/3623762.3633499

Schrepp, M. (2023, 12. September). *User Experience Questionnaire (UEQ) Handbook: All you need to know to apply the UEQ successfully in your projects* [Research report]. Version 11. Verfügbar 2. Dezember 2025 unter https://www.ueq-online.org

Schrepp, M., Hinderks, A., & Thomaschewski, J. (2014). Applying the User Experience Questionnaire (UEQ) in Different Evaluation Scenarios. In A. Marcus (Hrsg.), *Design, User Experience, and Usability. Theories, Methods, and Tools for Designing the User Experience* (S. 383–392). Springer International Publishing. https://doi.org/10.1007/978-3-319-07668-3_37

Shahu, A., Cipot, P., Asteriou, P., Wintersberger, P., & Michahelles, F. (2025). Integrating AI Assistants to Advance GIS Application Usability. *Proceedings of the 15th International Conference on the Internet of Things*, 1–8. https://doi.org/10.1145/3770501.3770502

Stegeman, M., Barendsen, E., & Smetsers, S. (2016). Designing a rubric for feedback on code quality in programming courses. *Proceedings of the 16th Koli Calling International Conference on Computing Education Research*, 160–164. https://doi.org/10.1145/2999541.2999555

Toba, H., Karnalim, O., Johan, M. C., Tada, T., Djajalaksana, Y. M., & Vivaldy, T. (2024). Inappropriate Benefits and Identification of ChatGPT Misuse in Programming Tests: A Controlled Experiment. In M. E. Auer, U. R. Cukierman, E. Vendrell Vidal & E. Tovar Caro (Hrsg.), *Towards a Hybrid, Flexible and Socially Engaged Higher Education* (S. 520–531). Springer Nature Switzerland. https://doi.org/10.1007/978-3-031-51979-6_54

Vihavainen, A., Airaksinen, J., & Watson, C. (2014). A systematic review of approaches for teaching introductory programming and their influence on success. *Proceedings of the Tenth Annual Conference on International Computing Education Research*, 19–26. https://doi.org/10.1145/2632320.2632349

Xinogalos, S. (2016). Designing and deploying programming courses: Strategies, tools, difficulties and pedagogy. *Education and Information Technologies*, *21*(3), 559–588. https://doi.org/10.1007/s10639-014-9341-9

Xue, Y., Chen, H., Bai, G. R., Tairas, R., & Huang, Y. (2024). Does ChatGPT Help With Introductory Programming? An Experiment of Students Using ChatGPT in CS1. *2024 IEEE/ACM 46th International Conference on Software Engineering: Software Engineering Education and Training (ICSE-SEET)*, 331–341. https://doi.org/10.1145/3639474.3640076

Abbildungsverzeichnis

3.1 Startansicht des Garden-Simulators mit ausgeführtem show-Befehl 7
3.2 Repository-Aufbau des „Garden-Simulators“ 8
3.3 Ausgabe des lokalen Testrunners bei fehlgeschlagenen und bestandenen Tests 10

Tabellenverzeichnis

3.1 Bewertungsraster V2 nach (Stegeman et al., 2016) 12

Formelverzeichnis

Abkürzungen

Anhang

Tooldokumentation

Hier sind alle genutzten (KI) Tools zu dokumentieren, die über die im Methodenkapitel eingesetzten Tools hinausgehen.

(KI) Tool	Anwendungsbereich	Betroffener Teil	Anmerkungen

Eidesstattliche Erklärung

„Ich erkläre hiermit an Eides statt, dass ich die vorliegende Arbeit selbständig ohne die Verwendung unerlaubter Hilfsmittel verfasst und keine anderen als die angegebenen Quellen verwendet habe. Alle Stellen, die wörtlich oder sinngemäß den angegebenen Quellen entnommen wurden, sind als solche kenntlich gemacht.

Sofern von der Studiengangsleitung eine Verwendung von Hilfsmitteln (insbesondere IT- und KI-gestützte) vorgesehen ist, erkläre ich, diese in der vorgelegten Arbeit mit dem jeweiligen Produktnamen und einer Beschreibung des genutzten Funktionsumfangs vollständig angeführt zu haben.

Zudem versichere ich, dass ich diese Arbeit gemäß der geltenden Prüfungsordnung der Hochschule für Angewandte Wissenschaften Burgenland sowie den Richtlinien der Österreichischen Agentur für wissenschaftliche Integrität zur guten wissenschaftlichen Praxis verfasst habe. Die Arbeit wurde bisher weder im Inland noch Ausland zur Begutachtung oder Beurteilung vorgelegt und nicht veröffentlicht.“

_____ _____

Ort, Datum Unterschrift